

### 3.4 Filosofia della trasparenza: spiegazione, giustificazione e verifica nell'IA

I paragrafi precedenti hanno messo in luce come le reti neurali, pur nella loro potenza predittiva, presentino limiti strutturali - opacità interna, instabilità, comportamenti non sempre controllabili - che rendono difficile comprenderne il funzionamento. Di fronte a questi limiti, la comunità scientifica ha proposto l'introduzione di proprietà da verificare formalmente, nel tentativo di riportare il comportamento del modello sotto controllo. Ma tutto questo solleva una questione più ampia: cosa significa davvero rendere un sistema algoritmico “trasparente”? E, soprattutto, la verifica formale può essere considerata una forma di spiegazione?

Il concetto di *trasparenza* ha una lunga storia nella filosofia della scienza, dove è stato spesso associato all'idea di intelligibilità, controllo e giustificabilità dei modelli teorici. In ambito algoritmico, però, questo concetto ha acquisito una pluralità di significati e funzioni, diventando inevitabilmente *multidimensionale*. Come sottolineano Mittelstadt et al. [31], la trasparenza non è una proprietà univoca, ma un insieme eterogeneo di criteri che variano a seconda del contesto e degli attori coinvolti. Possiamo distinguere almeno tre livelli:

- una **trasparenza meccanica**, che riguarda la possibilità di comprendere il funzionamento interno del sistema (struttura, pesi, attivazioni, flussi computazionali);
- una **trasparenza epistemica**, che richiede che le decisioni siano giustificabili e intelligibili: non solo *come* un output viene prodotto, ma *perché* è corretto o legittimo;
- una **trasparenza normativa**, che concerne la possibilità di controllo esterno, responsabilizzazione e contestazione delle decisioni algoritmiche.

In molti casi, questi livelli si sovrappongono solo parzialmente. Un modello può essere meccanicamente trasparente ma epistemicamente opaco (come una rete ReLU di poche unità), o al contrario essere una black-box ma sottoposto a garanzie legali. Quello che emerge è che la trasparenza non si identifica semplicemente con la “visibilità” del modello, ma coinvolge una rete complessa di relazioni tra chi produce l'algoritmo, chi lo usa, chi ne subisce le decisioni e chi è chiamato a valutarle.

La *spiegazione*, in questo quadro, è una componente essenziale ma non sufficiente della trasparenza. Spiegare un output - cioè fornire una motivazione intelligibile, comprensibile e giustificabile - è uno degli strumenti con cui si costruisce trasparenza, ma non l'unico. Altre strategie includono la rendicontazione, la sorveglianza, la certificazione o, appunto, la verifica formale.

In questo contesto, la verifica si colloca in una posizione interessante: da un lato, **non spiega nulla** nel senso classico - non dice quali feature hanno determinato l'output, né consente una lettura semantica della decisione. Dall'altro, **fornisce garanzie logiche** su certe proprietà del comportamento del modello. Dove la spiegazione manca, la logica può offrire un'alternativa affidabile.

Questa sostituzione è particolarmente rilevante nei modelli opachi: in assenza di strumenti interpretabili, l'unico modo per fidarsi del sistema è vincolarne il

comportamento. Come sottolinea Floridi [32], in molti casi l'obiettivo non è tanto comprendere l'algoritmo, quanto essere certi che non compia errori inaccettabili. Si passa così da una fiducia epistemica a una fiducia normativa.

In questo senso, la verifica formale non equivale alla trasparenza, né alla spiegazione. Ma può rappresentare una via alternativa per soddisfare la richiesta, sempre più pressante, di affidabilità, accountability e giustificabilità nei sistemi intelligenti. Non aiuta a capire “perché” una rete si comporta in un certo modo, ma può garantire - matematicamente - che non si comporterà mai in modo scorretto.